

Informe de resultados del grid search

Practica 5 — Mini LLM + NER sobre Alice in Wonderland

Grupo 7 — Hamza Triki, Alvaro Ferreño Iglesias

Resumen

El grid search confirma que, para el corpus pequeño de Alice in Wonderland, un modelo causal menos profundo generaliza mejor que variantes mas grandes o menos regularizadas. La mejor configuración causal fue la ejecución 02 (n_layers=2, val_loss=3.6607). En NER, el preentrenamiento sobre el modelo causal acelera la convergencia y, combinado con mayor dropout, permite obtener la mejor validación en la ejecución C (val_loss=0.1215, val_accuracy=0.9608).

- Mejor modelo causal: 02 layers=2, con mejor equilibrio entre capacidad y regularización.
- Principal riesgo observado: overfitting severo al quitar dropout o aumentar demasiado la profundidad.
- Mejor modelo NER: C pretrain + reg, beneficiandose tanto del transfer learning como de dropout=0.2.

1. Setup experimental

La arquitectura parte de un Transformer propio con embeddings de token y posicion, bloques pre-norm con self-attention multi-cabecal, conexiones residuales y red feed-forward GELU con expansion 4x. Sobre ese backbone se evaluaron dos cabezas: un modelo causal para generación de texto y un modelo NER por token con etiquetas BIO.

- Corpus causal: alice_in_wonderland.txt (~150 KB), tokenizer BPE con vocab_size=300 y contexto 128.
- Corpus NER: data/ner_dataset.json, 222 frases anotadas con un fuerte desbalance hacia la clase O y las entidades PER.
- Entrenamiento: AdamW, clipping de gradiente a 1.0, seed 42.
- Criterio de selección: se conserva el checkpoint con menor val_loss, no el ultimo epoch.

2. Resultados del grid search causal

Se ejecutaron siete ejecuciones variando un hiperparametro cada vez respecto a la baseline (d_model=128, n_layers=4, lr=3e-4, dropout=0.1, epochs=5, batch=64, context_size=128).

Ejecución	Cambio	best val_loss	Gap train-val	Diagnostico
01 baseline	Configuracion de referencia	3.7393	-1.07	Referencia estable
02 layers=2	Menos capas	3.6607	-0.19	Ganador: mejor equilibrio sesgo-varianza
03 layers=6	Mas capas	3.8139	-2.55	Overfitting moderado
04 d_model=64	Embedding mas pequeno	3.9157	-0.15	Underfitting por falta de capacidad
05 lr=1e-3	Learning rate alto	3.7559	-4.65	Converge rapido pero luego diverge
06 dropout=0	Sin regularizacion	4.0760	-8.04	Overfitting severo
07 epochs=10	Mas epocas	3.7393	-3.43	Mismo minimo; entrenar mas perjudica




Figura 1. Evolucion del val_loss para las distintas ejecuciones del grid search causal.

El patron dominante es claro: el corpus no soporta bien ni modelos mas grandes ni entrenamientos mas agresivos. La profundidad excesiva y la ausencia de regularización producen curvas con separación creciente entre train y validación, mientras que la reducción a dos capas mantiene la capacidad suficiente sin disparar el sobreajuste.

1. Menos capas funciona mejor: n_layers=2 mejora la baseline y evita el overfitting observado con 6 capas.
2. El dropout es esencial: al eliminarlo, la validación empeora de forma monótona pese a que train_loss cae mucho.
3. Un learning rate mas alto acelera el arranque, pero desestabiliza el entrenamiento tras las primeras épocas.
4. Reducir d_model a 64 evita el sobreajuste, pero a costa de perder demasiada capacidad representacional.
5. El mejor punto de parada esta alrededor de la época 4 o 5. Entrenar mas tiempo no aporta mejoras.

3. Resultados del grid search NER

Para NER se compararon tres ejecuciones centradas en dos factores: el uso de transfer learning desde el mejor modelo causal y el efecto de aumentar la regularización con un dataset pequeño y desbalanceado.

Ejecución	Pretrain	Dropout	Epochs	best val_loss	best val_acc	Convergencia
A noprtrain	No	0.1	8	0.1383	0.9580	Epoca 6
B pretrain	Si, causal ganador	0.1	8	0.1287	0.9605	Epoca 4
C pretrain + reg	Si, causal ganador	0.2	12	0.1215	0.9608	Epoca 6; mejora hasta la 11




Figura 2. Comparativa del mejor val_loss obtenido por cada ejecución NER.

6. El preentrenamiento ayuda sobre todo a converger antes: la ejecución B alcanza el umbral de 0.153 dos épocas antes que la A.
7. La mejor configuración NER fue la ejecución C, que combina el backbone causal ganador con dropout=0.2 y mas épocas.
8. La accuracy debe interpretarse con cuidado por el fuerte desbalance: la clase O domina la distribución de tokens.
9. Las entidades PER se detectan con mucha mas consistencia que LOC, debido al menor numero de ejemplos de localización.
10. La agregación a nivel palabra fue decisiva para evitar entidades truncadas generadas a partir de sub-tokens BPE.

4. Configuraciones seleccionadas

A partir del grid search se seleccionaron dos checkpoints finales para la entrega, uno para el LLM causal y otro para NER.

- Modelo causal entregado: ejecución 02 (n_layers=2, d_model=128, n_heads=4, expansion=4, dropout=0.1).
- Modelo NER entregado: ejecución C (backbone causal ganador, dropout=0.2, epochs=12, num_labels=5).
- Ambos checkpoints incluyen pesos, estado del tokenizer BPE, configuración de modelo, hiperparametros y métricas históricas.